

Sompo Sigorta Case Study

1. Veri Setinin Açıklaması ve verinin yapısı

Veri seti, yaklaşık 19.000 gözlemden oluşuyor ve 14 değişkene sahip. Değişkenler ve açıklamaları aşağıdaki gibidir.

Sütun Adı	Açıklama
TEKLİF NUMARASI	Teklifin sistemdeki unique numarası
HASARSIZLIK İNDİRİMİ KADEMESİ	Müşterinin kasko hasarsızlık indirimi kademesini temsil eder. (0 ile başlar, hasarsız her yıl artış gösterir, hasar durumunda düşer)
TRAFİK BASAMAK KODU	Müşterinin trafik hasarsızlık basamağını temsil eder. (4 ile başlar, hasarsız her yıl artış gösterir, hasar durumunda düşer)
MARKA	Aracın markası
ARAÇ YAŞI	Aracın yaşı
MODEL YILI	Aracın model yılı
YAKIT TİPİ	Aracın yakıt tipi
İL	Sigortalının ili
İLÇE	Sigortalının ilçesi
YAŞ	Sigortalının yaşı
TEKLİF PRİMİ	Sigortalının teklif primi
PORTFÖY AYRIMI	Poliçenin şirkette tekabül ettiği portföy alanı
SİGORTALI TİPİ	Sigortalının özel - tüzel müşteri olma durumu ayrımı
TEKLİF ONAY DURUMU	Sigortalıya sunulan teklifin onaylanma veya onaylanmama durumu (T-> Onaylanmadı, P-> Onaylandı)

Tablo1 : veri seti

2.Descriptive Statistics (Betimleyici İstatistikler)

Betimleyici istatistikler, verinin genel yapısını ve temel özelliklerini sayısal olarak ortaya koymak için kullanılan istatistiksel yöntemdir. Bu yöntem sayesinde veri setinin merkez eğilim ölçüleri (minimum değer, 1. Çeyrek , ortalama, medyan, maksimum değer) gibi bilgiler elde edilir. Olası veri problemlerini tespit etmek için önemli bir yöntemdir.

	Trafik.basamak.kodu	yaş	Teklif.primi
Minimum	1.000	0.0	2748
1.Çeyrek	5.000	0.0	8654


Medyan	6.000	36.0	11048
Ortalama	5.849	30.7	14394
3.Çeyrek	7.000	47.0	15243
Maksimum	8.000	64.0	646562

Tablo 2: Problemlı sayılabilecek değışkenlerin betimleyici istatistikleri


Yukarıdaki tabloda da görülebileceđi gibi verimizde yaşı ve trafik basamak kodu başta olmak üzere bazı düzeltilmesi gereken hatalar mevcut. Yaşların 0 girilmesi, , trafik basamak kodunun 4 değerinden küçük olması verinin eksik ve tamamlanması gerektiđini, teklif primi maksimum değerinin çok büyük olması ise görselleştirme yapılırken grafiklerin doğru şekilde veriyi aktaramayabileceđinin bir göstergesi. Bu eksikleri giderebilmek adına yaş değışkeni için KNN (en yakın komşı)imputasyon tekniđi kullanıldı. Trafik kodu değışkeninde değeri 4ten küçük olan gözlemlerin değeri 4'e alındı ve teklif primi değışkeni için görselleştirmenin düzgün gözükebilmesi adına log değışimi kullanıldı.

3. Keşifsel Veri Analizi (Exploratory Data Analysis)


Pie chart of Insurance Type




Pie Chart of Brands



Pie Chart of Fuel type




Pie Chart of Discount Level



Grafik 1 : Bazı kategorik değışkenlerin pasta grafikleri.

Kazım Tuğşad YAR

Pasta grafiklerinden de anlaşıldığı üzere, tekliflerin en çok yapıldığı sigortalı tipi, Özel sigortalı tipi, markalarda ise %37'lik bir dilimle Volkswagen ve %25'lik dilimle Ford diğer markalara göre daha çok teklif almış. Teklif alan bu araçların %53'ü benzinliyenken , %47'si ise dizel ile çalışıyor. Teklif alan insanların çoğunluğu indirimden yararlanamazken , yaklaşık %20'lik bir kısım maksimum indirimden yararlanabiliyor.





Grafik 2,3: Kategorik değişkenlerin teklif primi ile olan ilişki grafikleri.

Yukarıdaki keman ve kutu grafiklerine bakıldığında, en yüksek teklif primlerinin 7 değerindeki hasarsızlık kodundaki araçlara yapıldığı gözlemlenebilir fakat dağılımlar birbirine oldukça yakın.

Kazım Tuğşad YAR

Markalarda ise ortalama teklif primlerinin en yüksek olduđu marka Mercedes. Model yılı göz önüne alındığında yeni araçlar diğerlerine göre biraz daha fazla prim alabiliyor. Portföy ayrımı grafiğinde ise “Sıfır Araç” kategorisi dikkat çekiyor. Hem daha geniş hem de üst kısımlarda daha fazla yayılmış. Bu da bu grupta daha yüksek primlerin bu gruba verildiğine değiniyor.İllere göre teklif primi grafiğine baktığımızda çok büyük farklar göremiyoruz. Sadece istanbulun medyan çizgisi biraz daha yukarıda. Bu da demek oluyor ki diğerlerinden genel olarak daha yüksek tekliflere sahip.Hasarsızlık indirimi grafiğinde ise kademe (indirim) arttıkça teklif primleri düşme eğilimi gösteriyor.Bu beklenen bir durum. En düşük primler en yüksek indirim kategorisinde.





Grafik 4,5: İl ve markaya göre teklif primi treemap (ağaç haritası) ve Sunburst (güneş ışını grafiği)

Merkez katmandan dış katmana doğru ; Volkswagen ve Mercedes diğerlerine göre daha büyük alan kaplıyor, bu da daha fazla gözlem içerdiğini gösteriyor. Orta katman daha beklendiği gibi İstanbul'un en çok gözlem içerdiği şekilde dağılmış. Ağaç haritası da güneş ışını grafiğine benzer şeyler gösteriyor.

4. Modelleme

4.1 Genelleştirilmiş Doğrusal Model (Generalized Linear Model - GLM)

GDM, farklı türde verilerle çalışmamıza yardımcı olan esnek bir regresyon modelidir. Klasik doğrusal regresyondan farkı, sadece sayısal değil, aynı zamanda oran, sayım ya da kategorik gibi farklı türdeki verilerle de çalışabilmesidir. Bu modelde, hem bağımsız değişkenler kullanılarak bir tahmin yapılır hem de tahmin edilen değişkenin dağılımına uygun bir yöntem seçilir.

```
Call:
glm(formula = teklif.onay.durumu ~ hasarsizlik.indirimi.kademesi +
  trafik.basamak.kodu + marka + araç.yaşı + yakıt.tipi + il +
  yaş + teklif.prim + portföy.ayrimi + sigortalı.tipi, family = binomial(),
  data = data)

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept) -2.380e+00  1.792e-01 -13.285 < 2e-16 ***
hasarsizlik.indirimi.kademesi -8.143e-01  1.838e-01 -4.430 9.42e-06 ***
trafik.basamak.kodu -4.109e-03  2.084e-02 -0.197  0.84367
markaHONDA 8.078e-01  1.083e-01  7.456 8.95e-14 ***
markaMERCEDES 7.300e-01  9.566e-02  7.631 2.33e-14 ***
markaRENAULT 3.969e-01  8.808e-02  4.506 6.60e-06 ***
markaTOYOTA 5.585e-01  8.609e-02  6.488 8.71e-11 ***
markaVOLKSWAGEN 1.209e-01  7.291e-02  1.658 0.09725 .
araç.yaşı -3.881e-02  1.885e-02 -2.059 0.03953 *
yakıt.tipiDİZEL -1.960e-01  6.032e-02 -3.250 0.00116 **
İLİSTANBUL 9.441e-02  5.848e-02  1.614 0.10647
İLİZMİR 2.457e-01  7.550e-02  3.255 0.00113 **
yaş 8.015e-03  2.729e-03  2.937 0.00331 **
teklif.prim -6.700e-05  5.648e-06 -11.863 < 2e-16 ***
portföy.ayrimiSIFIR ARAÇ 1.246e+00  2.515e-01  4.955 7.23e-07 ***
portföy.ayrimiYENİ İŞ 5.097e-01  9.137e-02  5.578 2.43e-08 ***
portföy.ayrimiYENİLEME 2.101e+00  1.065e-01  19.719 < 2e-16 ***
sigortalı.tipi 1.077e+00  5.556e-02  19.382 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 14336  on 19084  degrees of freedom
Residual deviance: 12699  on 19067  degrees of freedom
AIC: 12735

Number of Fisher Scoring iterations: 6
```

Yandaki GLM çıktısında, Çoğu değişkenin önemli olduğunu görebiliyoruz. Bu kadar değişkene rağmen (serbestlik derecesi oldukça fazla) Null deviance = 14336 ve residual deviance = 12699 farkı çok düşük. Model için elde edilen McFadden R^2 değeri 0.114, bu değer, modelin yalnızca sabit terim içeren boş modele göre bağımlı değişken olan teklif.onay.durumu'nun gerçekleşip gerçekleşmeyeceğini tahmin etmede %11.4 oranında iyileşme sağladığını

göstermektedir.

Step fonksiyonu kullanılarak elde edilen yeni modelin, yukarıda gösterilmiş olan modelden neredeyse hiçbir farkı yok. Bu yüzden metrikleri de birbirlerine oldukça yakın.

	Accuracy	Sensitivity	Specificity	AUC	RMSE	MAE
GLM	0.874	0.98881	0.06613	0.746	0.3122745	0.1949671

Tablo 3 : Glm modeli performans metrikleri

4.2 Destek Vektör Makineleri (Support Vector Machines – SVM)

Support Vector Machine (SVM), özellikle sınıflandırmada kullanılan bir makine öğrenmesi algoritmasıdır. Bu algoritmada temel amaç, verileri birbirinden en iyi şekilde ayıracak bir sınır bulmaktır. Bu sınır, iki sınıf arasındaki boşluğu mümkün olduğunca geniş tutarak belirlenir. Böylece bu model, farklı sınıflara ait gözlemleri daha net ve doğru bir şekilde ayırabilir.

	Accuracy	Sensitivity	Specificity	AUC	RMSE	MAE
SVM	0.8755	0.060393	0.991223	0.6484	0.3262529	0.2124238
SVM_SMOTE	0.6854	0.66292	0.68861	-	0.5608789	0.3145852

Tablo 4 : SVM modeli performans metrikleri

Kazım Tuğşad YAR

4.3 Random Forest

Bu yöntem, birden fazla karar ağacının bir araya gelerek oluşturduğu bir modeldir. Modelin temel amacı, bireysel karar ağaçlarının tahminlerini birleştirerek daha doğru, kararlı ve genellenebilir sonuçlar elde etmektir.

Random Forest algoritması, her bir ağacı oluştururken veri setinden rastgele örnekler seçer ve her düğümde yalnızca rastgele seçilmiş bir alt değişken kümesi üzerinden bölünme işlemi yapar. Bu rastgelelik, ağaçlar arasında çeşitliliği artırarak modelin aşırı öğrenme yapma riskini azaltır.

	Accuracy	Sensitivity	Specificity	AUC	RMSE	MAE
RF	0.7321	0.7487	0.6152	0.7453	0.4300324	0.368984

Tablo 6 : Random forest model performans metrikleri

4.4 Xgboost


XGBoost (Extreme Gradient Boosting) gelişmiş bir topluluk öğrenme algoritmasıdır. Temel olarak gradient boosting yöntemine dayanır. Zayıf öğrenicileri (genellikle karar ağaçları gibi) art arda eğiterek güçlü bir tahmin modeli oluşturur. Her yeni model, bir önceki modelin hatalarını azaltmak amacıyla eğitilir. Diğer algoritmalara göre daha hızlı ve verimlidir. Eksik verilerle çalışabilir, karar ağaçlarını optimize eder ve düzenler (regularization). Bu sayede daha aşırı öğrenmeyi azaltıp karmaşık verilerle daha iyi performans verebilir.

	Accuracy	Sensitivity	Specificity	AUC	RMSE	MAE
Xgboost	0.7069	0.67275	0.71175	0.7588	0.4451772	0.3978563

Tablo 7 : Xgboost model performans metrikleri

4.5 Yapay Sinir Ağı (Artificial Neural Network – ANN)

Yapay Sinir Ağları (Artificial Neural Networks – ANN), insan beynindeki sinir hücrelerinden esinlenerek geliştirilmiş bir makine öğrenmesi yöntemidir. Temel olarak, veri girişini alıp bu veriyi bir dizi işlem katmanından geçirerek bir sonuç ya da tahmin üreten bir yapıdır. Üç kısımdan oluşur : giriş katmanı, gizli katmanlar ve çıktı katmanı. Giriş katmanları veriyi modele gönderir ve gizli katmanlar bu veriyi işleyerek çıktı katmanına verir. Çıktı katmanı ise modelin tahmini çıkarır.



Grafik 7: Nihai Neural Net modeli

Model önce gizli katman boyutları (size) ve düzenleme (decay) parametrelerinin optimum değerleri bulması için eğitilmiş, (sırasıyla 7 ve 0.05) daha sonrasında bulunan uygun parametre değerlerle nihai model oluşturulmuştur.

	Accuracy	Sensivity	Specifity	AUC	RMSE	MAE
ANN	0.6639	0.6577	0.7079	-	0.4714856	0.4213879

Tablo 8: Yapay nöron ağı modeli performans metrikleri

Model Metrikleri Açıklamaları

Accuracy (Doğruluk): Modelin doğru tahmin ettiği örneklerin, toplam örnek sayısına oranıdır. Genel başarı düzeyini gösterir.

Sensitivity (Duyarlılık , True Positive Rate): Gerçek pozitif örneklerin ne kadarının doğru tahmin edildiğini gösterir. Pozitif sınıfın doğru tespiti açısından önemlidir.

Specificity (Özgüllük , True Negative Rate): Gerçek negatif örneklerin ne kadarının doğru tahmin edildiğini gösterir. Negatif sınıfın doğru tanınması gereken durumlarda öne çıkar.

AUC (Area Under Curve) ROC eğrisi altındaki alanı temsil eder. Modelin sınıfları ayırma başarısını ölçer. 1'e yaklaştıkça performans artar.

RMSE (Root Mean Squared Error): Tahmin hatalarının karelerinin ortalamasının kareköküdür. Hata büyüklüğünü gösterir; düşük olması beklenir.

MAE (Mean Absolute Error): Tahmin hatalarının mutlak değerlerinin ortalamasıdır. Gerçek değerlere yakın tahminlerin göstergesidir; yine düşük olması tercih edilir.

Kazım Tuğşad YAR

Özetle, Tüm metrikler göz önüne alındığında GLM (Genelleştirilmiş Doğrusal Model), en iyi genel performansa sahip model olarak öne çıkıyor. En yüksek doğruluk (accuracy) (%87), en yüksek duyarlılık (sensitivity) (%98) ve en düşük hata oranları (RMSE ve MAE) bu modelde.

XGBoost algoritması AUC açısından en yüksek değere sahip olsa da, diğer metrikler açısından GLM kadar etkili değildir. Diğer modeller ise genellikle daha yüksek hata oranlarına ve daha düşük doğruluk seviyelerine sahiptir. Sonuç olarak, GLM bu problem için en uygun modeldir.

Model	Accuracy	Sensitivity	Specificity	AUC	RMSE	MAE
GLM	0.8740	0.98881	0.06613	0.746	0.3123	0.1950
SVM	0.6854	0.66292	0.68861	-	0.5609	0.3146
DT	0.6706	0.66610	0.70220	0.7289	0.5738	0.3294
RF	0.7321	0.74870	0.61520	0.7453	0.4300	0.3690
XGBoost	0.7069	0.67275	0.71175	0.7588	0.4452	0.3979
ANN	0.6639	0.65770	0.70790	-	0.4715	0.4214

Tablo 9 : Bütün modellerin performans metrikleri

Eğer şirket portföyü artırarak teklif priminden feragat etmek istiyorsa, daha yüksek indirim uygulayarak daha fazla insana ulaşabilir. Müşterileri gruplara ayırarak indirim oranını kâr oranına göre düzenleyebilir. Örneğin eğer özel müşteriler fiyata duyarlıysa, bu kitleye %7'lik indirim teklif edilebilir. Ancak, tüzel müşteriler için daha düşük indirimler sunarak, daha yüksek kâr sağlanabilir. İndirimin artırıldığı durumlarda şirket, ek servis, hizmet veya fazladan indirimli sigorta ürünü sunarak bu indirimden kaybettiği kârı azaltabilir (çarpraz satış). Daha sonrasında anketlerle kullanıcılardan geri bildirim alarak veya A/B testleri uygulayarak hangi indirim stratejisinin daha uygun olduğunu belirleyebilir. %3 indirim portföyde %8lik büyüme sağlarken, %10 indirim %13'lük büyüme sağlanıyor. Ama %3'lük indirimin kâr marjını azalttığını varsayalım. Burada, portföy büyümesi ve kâr kaybı arasında denge kurarak %5-6 civarında bir indirim oranı seçilebilir.